


## GEMİ TESPİTİ UYGULAMASINDA YOLOV8 VE YOLOV9 ALGORİTMALARININ PERFORMANS DEĞERLENDİRMESİ

Bu makalede, gemi tespiti ve sınıflandırması incelenmiştir. Deniz gözetimi ve izleme alanında kritik bir konu olan gemi tespiti; balıkçılık yönetimi, göçmen izleme, deniz kurtarma ve deniz savaşları gibi amaçlarla gerçekleştirilir.

Uzaktan algılama teknolojileri, yüksek zamanlılık, geniş kapsama alanı, düşük maliyetli erişim sağlaması ve coğrafi koşullardan bağımsız olması nedeniyle gemi izleme için birincil yöntem olarak öne çıkmaktadır. Gemi tespiti için **SPOT-5**, **QuickBird**, **HRSC2016**, **Sentinel-1**, **SSDD** ve **FGSD** gibi birçok veri seti kullanılarak **CNN** ve **Transformer** tabanlı derin öğrenme modelleri incelenmiştir. Ancak, gemi tespitinin diğer nesne tespiti çalışmalarına kıyasla daha az gelişmiş olduğu gözlemlenmiştir.

YOLO mimarisinin tercih edilmesinin temel nedeni, hızlı ve doğrudan sonuç vermesidir. Yapılan çeşitli iyileştirmelerle **SAR-LtYOLOv8** gibi modeller, ölçek bağımsız özellikleri geliştirerek küçük nesnelerin algılanmasını optimize etmektedir. Benzer şekilde, **Ship-Fire Net**, gemi yangınlarını hem iç hem de dış mekânda tespit eden hafif yapısıyla yüksek hızlı ve hassas bir çözüm sunmaktadır. Bu nedenle, YOLOv8 tabanlı modeller, doğruluk ve kapsam açısından dengeli sonuçlar vererek karmaşık deniz senaryolarında umut vadeden bir çözüm olarak değerlendirilmektedir.

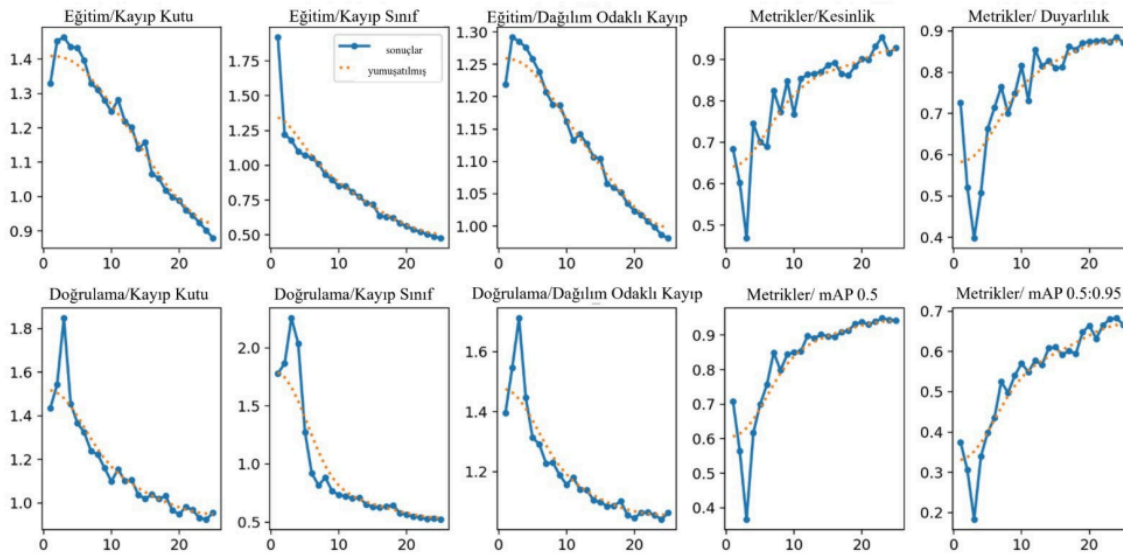
Bu çalışmada **YOLOv8** ve **YOLOv9** kullanılmıştır. YOLO (**You Only Look Once**) nesne algılama görevini, hesaplama karmaşıklığını azaltan tek bir regresyon problemi olarak ele almaktadır. Zamanla YOLO'nun yeni sürümleri geliştirilmiş ve her yıl daha yüksek performans göstermiştir. YOLO, üç ana bölümden oluşur: **Omurga (Backbone)**, **Boyun (Neck)** ve **Baş (Head)**.



**YOLOv8**, kullanıcılara kapsamlı geliştirmeler ve çok yönlü yetenekler sunmaktadır. YOLOv8 tarafından önerilen **C2f (Cross Stage Partial) modülü**, derin öğrenme ağlarını iyileştirerek modelin daha kısa sürede daha yüksek performans göstermesine olanak tanımaktadır.

**YOLOv9** modelinde ise omurga ağının birincil işlevi, giriş görüntüsünden özellikler çıkarmaktır. Önceki YOLO modellerinde kullanılan bloklar entegre edilerek modelin kapasitesi artırılmış ve doğruluk oranları yükseltilmiştir.

Veri Seti olarak "Ships in Google Earth" veri seti kullanılmıştır. Bu veri setinde %86 eğitim, %10 doğruluk ve %5 lik bir kısmı test için ayrılmıştır. Öncelikle bu veriler otomatik yönlendirme yapılarak veri ön işleme adımlarından geçmişler tekrar boyutlandırılmıştır. daha iyi başarımlar elde etmek için data augmentation adımları izlenmiştir.



**Şekil 3.** YOLOv8 Eğitim Metrikleri (YOLOv8 Training Metrics)

Araştırma bulgularına göre kesinlik, duyarlılık ve ortalama hassasiyet (mAP) ölçülmüştür. Eğitim kayıpları açısından bakıldığında; YOLOv8 ve YOLOv9'un eğitim kayıp değerleri iterasyon sayısı arttıkça azalma eğilimi göstermektedir. Ancak, YOLOv8'in kayıp eğrileri daha yumuşak olup daha stabil bir eğitim süreci sunduğu görülmüştür. YOLOv9'un eğitim kayıpları başlangıçta daha hızlı düşüş göstermekte, bu da modelin daha hızlı yakınsadığını göstermektedir.

Her iki modelin doğrulama kayıpları da zamanla azalmakta, ancak eğitim kayıplarına kıyasla daha fazla dalgalanma göstermektedir. YOLOv9'un doğrulama kayıplarının son aşamada daha düşük olduğu gözlemlenmiş ve bu da modelin doğrulama setinde daha iyi genelleme performansı sergilediğini göstermektedir.

Her iki model de yüksek Intersection over Union (IoU) eşiklerinde iyi performans sergilemektedir. Ancak, YOLOv9'un daha küçük veya kısmen gizlenmiş nesneleri tespit etmede hafif bir üstünlük sağladığı görülmüştür.

YOLOv8 ve YOLOv9, gemi tespiti için incelenmiştir. YOLOv9, mAP ve duyarlılık açısından YOLOv8'den biraz daha iyi performans göstermektedir. Özellikle erken iterasyonlarda daha hızlı yakınsadığı gözlemlenmiştir. Eğer tespit kalitesi öncelikliyse, YOLOv9 tercih edilebilir. Ancak seçim, çıkarım hızı ve hesaplama verimliliği gibi faktörlere de bağlıdır.

## Mask R-CNN İle Uydu Görüntülerinde Gemi Tespiti

Gemi tespitinde **CNN** tabanlı nesne tespiti ve sınıflandırma yöntemleri yaygın olarak kullanılmaktadır. Ayrıca, uydu görüntülerinin gelişimi bu alanda önemli ilerlemelere yol açmıştır. Bu çalışmada, **optik uydu görüntülerindeki gemileri tespit etmek için** bölge tabanlı konvolüsyonel sinir ağı modellerinden biri olan **Mask R-CNN** yöntemi kullanılmıştır.

Geçmişte yapılan çalışmaların büyük çoğunluğu makine öğrenmesine dayalı olup, standart sapma gibi ölçütlerde performans düşüşleri gözlemlenmiştir. CNN modellerinin gelişimiyle birlikte sınıflandırma alanında büyük başarılar elde edilmiştir. Ancak, nesnenin görüntü üzerinde kapladığı alan küçük olduğunda ve konumuyla birlikte çıkarılması gerektiğinde, nesne tespitinde ek uyarlamalara ihtiyaç duyulmaktadır.

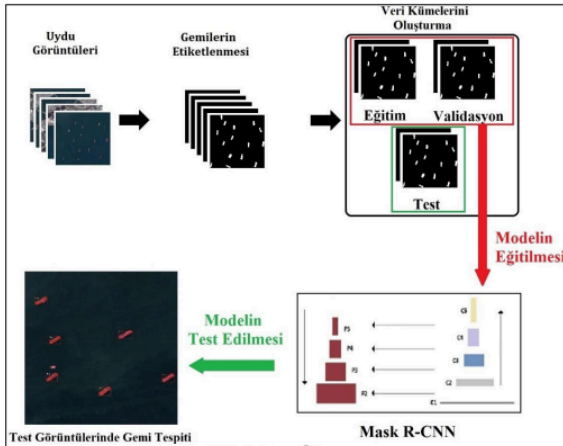
Bu probleme çözüm olarak kayan pencereler (sliding windows) yaklaşımı kullanılmıştır. Ancak, bu yöntem zaman alıcı ve maliyetli olduğundan, CNN tabanlı iki farklı tespit yaklaşımı önerilmiştir.

**Bölge Tabanlı Yöntemler:**İki aşamalı bir süreç ile önce nesne olma potansiyeli yüksek bölgeler belirlenir, ardından sınıflandırma ve sınırlayıcı kutular üretilir. Faster R-CNN ve Mask R-CNN bu gruba dahildir.

**Doğrudan Tahmin Yapan Yöntemler:**Bölge öneri ağına ihtiyaç duymadan, nesne tespitini doğrudan görüntü özelliklerinden tahmin eder. **YOLO ve SSD** bu yöntemlere örnek olarak gösterilebilir.

Bölge-tabanlı konvolüsyonel sinir ağları (R-CNN) yönteminde, görüntüde nesne aday bölgeler belirlenmekte ve özellik çıkarımı konvolüsyonel katmanlar aracılığıyla gerçekleştirilmektedir. Bu türdeki tespit yöntemlerinden olan Mask R-CNN'de nesne konumlarının belirlenmesi de öğrenme yoluyla gerçekleştirilmektedir

Ham görüntülerden başlayan süreçte öncelikle görüntüler işlenip etiketlenmekte ve veri setleri oluşturulmaktadır. Ardından bu veriler kullanılarak model eğitilmekte ve test görüntülerdeki gemilerin tespitiyle süreç tamamlanmaktadır. Bu başlıkta sırasıyla çalışmada kullanılan verilere, gemi tespiti için önerilen modele, modelin eğitime dair detaylara ve tespit değerlendirme metriklerine yer verilmektedir.



Şekil 1.Çalışmadaki Gemi Tespit Prosedürü

Bu çalışmada, **Google Earth tarafından sağlanan RGB uydu görüntüleri** kullanılmıştır. Ham görüntüler işlenmiş, etiketlenmiş ve **eğitim, doğrulama ve test veri setleri** oluşturulmuştur. Görüntüler, **GIS yazılımı** kullanılarak sayısallaştırılmış ve modelin eğitimi gerçekleştirilmiştir. Eğitim tamamlandıktan sonra modelin performansı test edilerek analiz edilmiştir.

Mask R-CNN, nesneleri tespit ederek **maskeler oluşturur, sınırlayıcı kutular belirler ve her tespitin olasılık değerini hesaplar**. Modelin yapısı dört temel bileşenden oluşmaktadır:


- Özellik Çıkarım Ağı (Feature Extraction Network)
- Bölge Öneri Ağı (Region Proposal Network - RPN)
- Öneri İşleme Modülü (Proposal Processing Module)
- Bölge Tabanlı Konvolüsyonel Sinir Ağı (Region-Based CNN - R-CNN)

Bu çalışmada kullanılan Mask R-CNN sürümünde özellik çıkarımı, **Özellik Piramit Ağı (Feature Pyramid Network – FPN)** tarafından yapılmaktadır. **FPN**, yüksek çözünürlüklü ancak düşük semantik değerli katman özelliklerini, derin katmanlardaki yüksek semantik değerlerle birleştirerek daha iyi nesne tespiti sağlamaktadır.

Modelin eğitimi sürecinde **5 adet kayıp fonksiyonu (loss function)** tanımlanmış ve model **80 bin iterasyon boyunca eğitilmiştir**. Modelin performansını değerlendirmek için **kesinlik (precision)**, **geri getirme (recall)** ve **F1 skoru** gibi yaygın metrikler kullanılmıştır.

Yapılan testler sonucunda **optimal güven eşiği 0,5** olarak belirlenmiştir. Bu değerde, modelin **test kümesindeki 604 gemiden 558'ini doğru tespit ettiği, 46 gemiyi gözden kaçırdığı ve 58 yanlış alarm ürettiği** gözlemlenmiştir. Modelin metrik değerleri şu şekilde hesaplanmıştır: Geri getirme (Recall): 0,9238 , Kesinlik (Precision): 0,9058, F1 Skoru: 0,9148

yapılan gerçek hayat testleri: Singapur Limanı açıklarından alınmış bir görüntü olan Şekil 4.a'da herhangi bir kara parçası yoktur. Toplam sekiz geminin bulunduğu bu görüntü için model yedi gemiyi doğru tespit etmiş, kırmızı yuvarlakla yakınlaştırılmış alanda yer alan büyük gemiye yanaşmış olan küçük gemiyi gözden kaçırmıştır



Şekil 4. Açık Denizde Bulunan Gemileri İçeren Bir Uydu Görüntüsü (a) ve Modelin Bu Görüntü İçin Ürettiği Tespit Sonucu (b)

Bu çalışmada Mask R-CNN kullanılarak uydu görüntülerinde gemi tespiti gerçekleştirilmiş ve modelin performansı detaylı bir şekilde incelenmiştir. Modelin güçlü yanları, yüksek hassasiyetle tespit yapabilmesi ve uygulamalarda başarılı sonuçlar vermesi olarak

belirlenmiştir. Ancak, birbirine yakın nesneleri ayırt etme konusunda bazı sınırlamalar taşıdığı gözlemlenmiştir.

### **Gelişmiş Deniz Gözlemi: SAR Tabanlı Gemi Tespiti için CNN Algoritmalarının Kullanımı**

Bu proje, SAR (Sentetik Açıklıklı Radar) görüntülerine dayalı gemi tespiti için Faster R-CNN algoritmasını kullanarak deniz gözetimini geliştirmeyi amaçlamaktadır. Sentinel-1 uydu verileri ile derin öğrenme tabanlı nesne tespiti birleştirilerek, gemi tespiti, deniz güvenliği, gemi trafiği yönetimi ve çevresel izleme gibi alanlarda uygulanabilir bir model geliştirilmiştir.

**Sentinel-1**, Avrupa Uzay Ajansı (ESA) tarafından geliştirilen ve yüksek mekânsal çözünürlüğe sahip SAR görüntüleri sağlayan bir radar uydusudur. Bu özellikleri nedeniyle, deniz gözetimi için uygun bir veri kaynağıdır. Faster R-CNN modeli kullanılarak SAR görüntülerinde yüksek doğrulukla gemi tespiti sağlanması hedeflenmiştir. Model, konvolüsyonel **sinir ağları (CNN)** ve **bölge öneri ağlarını (RPN)** birleştirerek **nesne tespiti yapmaktadır**.

Çalışmada **Sentinel-1 SAR** verileri kullanılmıştır. SAR görüntüleri, optik sensörlerin aksine hava koşullarından ve aydınlatmadan bağımsız olarak çalışabilme avantajına sahiptir. Bu özellik, modelin gece ve olumsuz hava koşullarında da gemi tespiti yapabilmesini sağlamaktadır. Kullanılan Faster R-CNN modeli, iki ana bileşenden oluşmaktadır:

- 1. Bölge Öneri Ağı (RPN):** Girdi görüntülerinden nesne adaylarını belirleyerek modelin işleme sürecini hızlandırır.
- 2. Nesne Algılama Ağı:** RPN tarafından önerilen bölgeleri sınıflandırır ve gemi olup olmadığını belirleyerek sınır kutularını oluşturur[18].

Modelin eğitimi sırasında, SAR görüntülerindeki gemilerin belirlenmesi için veri ön işleme adımları uygulanmıştır. Gürültü temizleme, kontrast artırma ve veri artırma (data augmentation) gibi teknikler kullanılarak modelin daha geniş koşullarda başarılı çalışması sağlanmıştır.

Modelin başarısını ölçmek için yaygın olarak kullanılan kesinlik (Precision), geri getirme (Recall) ve F1-Skoru metrikleri kullanılmıştır. Elde edilen sonuçlar şu şekildedir:

- Genel doğruluk oranı: %86.11
- Kesinlik (Precision): %84.54
- Geri getirme (Recall): %89.03

Bu değerler, modelin hem yüksek doğrulukla tespit yapabildiğini hem de yanlış pozitif oranının düşük olduğunu göstermektedir.

Harita, tespit edilen gemilerin görüntünün çeşitli alanlarına dağıldığını ve bu konumlarda nakliye faaliyetinin varlığını göstermektedir. Önerilen algoritma küçük balıkçı teknelerinin yanı sıra büyük kargo gemilerini de yüksek doğrulukla tespit edebilmiştir. Yanlış pozitif oranının da düşük olması, algoritmanın görüntülerdeki diğer özellikleri gemi olarak yanlış tanımlamadığını göstermektedir. Önerilen gemi tespit algoritması, Sentinel-1 VH SAR görüntülerinden oluşan test veri kümesi üzerinde %86,11'lik bir genel doğruluk elde etmiştir. Algoritma, kargo gemileri, balıkçı tekneleri ve konteyner gemileri dahil olmak üzere farklı boyut ve şekillerdeki gemileri başarıyla tespit etti. Kesinlik (presicion) ve geri çağırma (recall)

